

# Stock Beta CAPM

Tu nombre aqui

Fecha

## Abstract

Statatistical treatment for data in fitting the CAPM

## Contents

<b>1</b>	<b>Riesgo de Mercado medido por el CAPM</b>	<b>1</b>
1.1	El problema . . . . .	1
1.2	El modelo . . . . .	1
<b>2</b>	<b>Implementación</b>	<b>1</b>
2.1	Detalles Técnicos . . . . .	1
2.2	Modelo: Implementación . . . . .	4
<b>3</b>	<b>Bibliografía</b>	<b>5</b>

# 1 Riesgo de Mercado medido por el CAPM

## 1.1 El problema

En el contexto de **Asset Pricing** nos encontramos con el problema de *estimar* el precio (en terminos de su retorno así como el riesgo asociado a este retorno) de los activos riesgosos.

Una manera de tratar este problema lo propusieron *Jack Treyno* (1961, 1962), *William F. Sharpe* (1964) y *John Lintner* (1965) partiendo de un problema de maximización/minimización de la razón retorno - riesgo para un portafolio de activos riesgosos.

Específicamente el CAPM es una herramienta que pretende medir la relación entre el *retorno esperado* de un activo y su relación con el *riesgo sistemático*.

En los ramos de las finanzas corporativas y administración de portafolios el uso del CAPM es *EL* modelo más utilizado, no solo desde la perspectiva de asset pricing, si no como una métrica de desempeño para los portafolios.

En este documento estudiaremos los retos que implica la implementación de este modelo con datos del mundo real, así como un somero repaso de los supuestos detras del CAPM.

## 1.2 El modelo

En un portafolio de activos riesgosos, al aumentar el no. de activos, el riesgo instrínseco que aporta cada activo, medido por la desviación estándar, tiende a anularse. Es decir, para un portafolio bien diversificado  $\sigma_p \rightarrow 0$ . Sin embargo hay unidades residuales de riesgo no atribuibles a los activos sino al mercado que permanecen latentes aún ante una diversificación “completa”. ¿Cómo medimos este riesgo residual?

Muy a grandes rasgos, si consideramos que el retorno de los activos se puede explicar mediante el modelo de un solo factor, con este siendo el retorno del mercado al resolver el problema de maximización:  $\max\{r_p\} \frac{r_p - r_f}{\sigma_p} = \text{sharpe ratio}$  s.a  $\sigma_p > 0$  encontraremos no solo que la combinación de activos que maximiza las unidades de retorno en exceso de una unidad de riesgo es de hecho el portafolio de mercado, si no que, el número que mide el riesgo sistemático existe y se le conoce como la beta ( $\beta$ ) del activo.

Por la manera en la que se plantea el problema este número coincide con la beta de ua reggression lineal entre el mercado, la tasa libre de riesgo y el activo al que queremos ponerle precio. Esta relación tiene la siguiente forma  $r_a = r_f + \beta_a[r_m - r_f]$ .

# 2 Implementación

Para estimar el modelo utilizaremos el modelo de mercado propuesto por Fama & MacBeth de la forma  $r_a - r_f = \beta_a[r_m - r_f]$  y ajustaremos un modelo de regresión normal simple sobre estos datos.

Si el modelo es correcto la interssión debería ser cero, generalmente esto no ocurre y a estas desviaciones del CAPM se le conoce como la  $\alpha$  del activo y son muy utilizadas como mpetricas de desempeño para los administradores de activos.

## 2.1 Detalles Técnicos

1. Para la implementación de este modelo como propuesto por Fama & MacBeth partimos de 5 años de datos de precios diarios.
2. Usaremos precios diarios ajustados (por dividendos)
3. Generalmente va a ocurrir que el mundo real es bastante feo y nos vamos a encontrar con información incompleta debemos darle un tratamiento especial a estos datos.

4. Debe haber información completa para todo el periodo del activo y el mercado.
5. La tasa libre de riesgo debe ser de hecho libre de riesgo y debe corresponder al horizonte de inversión.

### 2.1.1 Resumen de Datos

Resumen datos con periodicidad diaria

Table 1: Resumen de datos 1

date	tesla	sp	rf
Min. :2015-02-06	Min. :-0.1717584	Min. :-0.0409792	Min. :0.00210
1st Qu.:2016-05-18	1st Qu.: -0.0127050	1st Qu.: -0.0027756	1st Qu.:0.00580
Median :2017-08-17	Median : 0.0008028	Median : 0.0005562	Median :0.01230
Mean :2017-08-14	Mean : 0.0014393	Mean : 0.0004834	Mean :0.01342
3rd Qu.:2018-11-08	3rd Qu.: 0.0165998	3rd Qu.: 0.0046701	3rd Qu.:0.02060
Max. :2020-02-05	Max. : 0.1989486	Max. : 0.0495937	Max. :0.02740
NA	NA	NA	NA's :9


Classes 'tbl\_df', 'tbl' and 'data.frame': 1238 obs. of 4 variables: \$ date : Date, format: "2015-02-06" "2015-02-10" ... \$ tesla: num 0 -0.00492 -0.01614 -0.04662 0.00439 ... \$ sp : num 0 0.010676 -0.000029 0.009645 0.004075 ... \$ rf : num 0.0026 0.0025 0.0024 0.0023 0.0023 0.0025 0.0023 0.0023 0.0023 0.0022 ...

Encontramos datos no disponibles (NA's) en las columnas *tesla* Y *rf*, debemos de imputarlos por un método adecuado y tenerlos siempre en el radar.

### 2.1.2 Tratamiento de datos faltantes

#### 2.1.2.1 Visualización

## Datos faltantes



Creamos “Datos Nabulares” para rastrear los datos faltantes y las imputaciones e imputamos por combinación lineal.

### 2.1.3 Agregación y Temporalidad


Estamos trabajando con retornos diarios, según el procedimiento propuesto por Fama & MacBeth debemos agregar los datos a temporalidad mensual y con estos 60 puntos de información ajustar el modelo de regresión.

**2.1.3.1 Agregados vs. Promedios** Hay una discusión importante sobre que tipo de retornos son un mejor proxy para el retorno esperado (que no podemos observar con anticipación) los compuestos ( $\prod_{i=1}^n (1 + r_i)$ ) o los promedio ( $\frac{1}{n} \sum_{i=1}^n r_i$ ).

Nosotros usaremos retornos esperados promedio tomando como punto de partida el argumento (económico y estadístico) de que el promedio suaviza las *sorpresas de información* introduciendo menos **ruido** (variabilidad) al modelo y por ende mejorando el ajuste.

## 2.2 Modelo: Implementación

### 2.2.1 Visualización



### 2.2.2 Resultados

Table 2: Estimación puntual

term	estimate	std.error	statistic	p.value
(Intercept)	0.002511	0.001965	1.278	0.2063
rp	1.082	0.1296	8.349	1.412e-11

Table 3: Estimación por regiones

	2.5 %	97.5 %
(Intercept)	-0.001421	0.006443
rp	0.8227	1.341

### 2.2.3 Discusión: ¿Qué hacer con los outliers?

Como podemos apreciar en la visualización del modelo hay ocasiones en las que podemos encontrar observaciones atípicas que pueden afectar en mayor o menos medida el ajuste del modelo. El que hacer con ellos es un gran tema de estudio así como el del tratamiento de datos faltantes.

### 2.2.3.1 Reto

- Retira el outlier del DF “modelo” y vuelve a ajustar el modelo de regresión. Reporta:
  - Visualización (Con  $r^2$ )
  - Resultados del modelo
  - Tip: usa `dplyr::filter` y el operador “distinto de” `!=`

## 3 Bibliografía

1. Investopedia
2. Wikipedia
3. StackOverflow